

Edson Alessandro F. Costa

Aplicação de técnicas de imputação de dados a SHM

Brasil

2018

Edson Alessandro F. Costa

Aplicação de técnicas de imputação de dados a SHM

Trabalho de Conclusão de Curso submetido à
Universidade Federal do Pará, como requisito
necessário para obtenção do grau de Bacharel
em Ciência da Computação

UNIVERSIDADE FEDERAL DO PARÁ
INSTITUTO DE CIÊNCIAS EXATAS E NATURAIS
FACULDADE DE COMPUTAÇÃO
CURSO DE BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO

Orientador: Prof. Dr. Claudomiro de Souza de Sales Junior

Brasil

2018

Edson Alessandro F. Costa

Aplicação de técnicas de imputação de dados a SHM/ Edson Alessandro F. Costa. – Brasil, 2018-

20 p. : il. (algumas color.) ; 30 cm.

Orientador: Prof. Dr. Claudomiro de Souza de Sales Junior

Trabalho de Conclusão de Curso – UNIVERSIDADE FEDERAL DO PARÁ
INSTITUTO DE CIÊNCIAS EXATAS E NATURAIS
FACULDADE DE COMPUTAÇÃO
CURSO DE BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO , 2018.

1. SHM 2. Imputação de Dados 2. Detecção de Danos I. Prof. Dr. Claudomiro de Souza de Sales Junior. II. Universidade Federal do Pará. III. Faculdade de Computação. IV. Aplicação de técnicas de imputação de dados a SHM

CDU 02:141:005.7

Edson Alessandro F. Costa

Aplicação de técnicas de imputação de dados a SHM

Trabalho de Conclusão de Curso submetido à
Universidade Federal do Pará, como requisito
necessário para obtenção do grau de Bacharel
em Ciência da Computação

Trabalho em andamento. Brasil, 24 de novembro de 2012.

**Prof. Dr. Claudomiro de Souza de
Sales Junior**
Orientador

Professor
Convidado 1

Professor
Convidado 2

Brasil
2018

Resumo

Resumo a ser feito

Palavras-chaves: latex. abntex. editoração de texto.

Abstract

This is the english abstract.

Key-words: latex. abntex. text editoration.

Lista de ilustrações

Lista de tabelas

Lista de abreviaturas e siglas

SHM	Monitoramento de Integridade Estrutural - <i>Structural Health Monitoring</i>
FN	Falso Negativo
FP	Falso Positivo

Lista de símbolos

Γ	Letra grega Gama
Λ	Lambda
ζ	Letra grega minúscula zeta
\in	Pertence

Sumário

1	INTRODUÇÃO	11
1.1	Trabalhos Relacionados	12
1.1.1	Imputação ou recuperação de dados em SHM	12
1.1.2	Comparação de métodos de imputação de dados	13
1.2	Motivação	14
1.3	Justificativa	15
1.4	Objetivos	16
1.4.1	Objetivo Geral	16
1.4.2	Objetivos Específicos	16
1.5	Metodologia	17
1.6	Organização	18
	REFERÊNCIAS	19

1 Introdução

As estruturas civis e industriais são onipresentes em todas as sociedades, independentemente da cultura, religião, localização geográfica e desenvolvimento econômico. O mau funcionamento de estruturas civis geralmente tem sérias consequências e mesmo quando não há perda de vidas, as populações sofrem se a infraestrutura estiver parcial ou completamente fora de serviço. As estruturas mais seguras e duráveis são aquelas que são bem gerenciadas e as atividades de medição e o monitoramento geralmente têm papéis essenciais nas atividades de gerenciamento. Os dados resultantes de um programa de monitoramento são usados para otimizar a operação, manutenção, reparo e substituição da estrutura com base em dados confiáveis e objetivos (GLIŠIĆ; INAUDI, 2007).

Consequentemente, a instalação de sistemas sofisticados e de longo prazo de monitoramento de saúde estrutural nessas infraestruturas importantes tornou-se uma tendência a fim de avaliar seu desempenho e condição, detectar seus danos e orientar sua manutenção com os objetivos finais de assegurar as estruturas funcionem de forma adequada e segura durante todo o seu ciclo de vida e prevenindo-as de falhas catastróficas em eventos extremos(LI; YI; QIAO, 2017).

Dentro desse contexto entra o paradigma de Monitoramento de Integridade Estrutural (*Structural Health Monitoring* - SHM) que visa dar, a cada momento do tempo de vida de uma estrutura, um diagnóstico do estado dos materiais constituintes, das diferentes partes, e da montagem completa dessas partes constituindo a estrutura como um todo(BALAGEAS; FRITZEN; GÜEMES, 2010).

A fim de oferecer esse diagnóstico do estado das estruturas, sinais de vibração podem ser medidos a partir de diferentes tipos de sistemas de monitoramento através de uma diversidade de sistemas de aquisição de dados e sensores. Com base no tratamento de dados adequado, informações valiosas da dinâmica estrutural podem ser extraídas e usadas como características sensíveis a dano a fim de detectar danos estruturais precoces e progressivos, aumentando assim a segurança, evitando colapsos e apoiando o processo de tomada de decisão sobre manutenção, reparo e reabilitação(SANTOS et al., 2016).

Em geral, o monitoramento da integridade das estruturas requer a instalação de um grande número de sensores em toda uma estrutura capaz de coletar dados detectados. Os dados coletados são processados para que as decisões sobre a integridade geral da estrutura possam ser tomadas(NOEL et al., 2017).

No entanto, um problema crítico para todos os sistemas de monitoramento de integridade estrutural é a perda de dados ou a corrupção de dados devido à falha do sensor ou outros problemas de funcionamento, o que influencia diretamente a análise e tomada

de decisões subsequentes (CHEN et al., 2017). No caso extremo, pode haver uma perda completa de informações de sensores devido a uma falha abrupta dos mesmos (BALABAN et al., 2010).

No monitoramento de saúde estrutural civil, os erros causados pela perda de dados afetam inevitavelmente a análise de dados da estrutura e a tomada de decisão subsequente (BAO et al., 2013). Em relação à influência de dados perdidos na análise estrutural, estudos mostraram que o impacto da perda de dados de 0,5% é similar com a adição de ruído de 5% na estimativa da densidade espectral de potência (PSD). Além disso, verificou-se que a perda de dados introduziu erros na análise do modelo e, portanto, impactou o diagnóstico estrutural (SPENCER; NAGAYAMA; BRIDGE, 2008).

Dessa maneira, a fim de superar o obstáculo dos dados faltantes, a imputação de dados surge como alternativa. Várias estratégias inspiradas em estatística e aprendizado de máquina foram desenvolvidas para resolver o problema da imputação de dados. Uma revisão da literatura revela que a eficácia dos métodos propostos depende fortemente do problema domínio (por exemplo, número de casos, número de variáveis, padrões de omissão) e, portanto, não há indicação clara que favoreça um método sobre os outros (JEREZ et al., 2010).

Esse trabalho tem por objetivo então avaliar as técnicas de imputação de dados dentro do contexto de monitoramento de integridade estrutural (*Structural Health Monitoring* - SHM).

1.1 Trabalhos Relacionados

No que se refere aos trabalhos relacionados, a revisão desses estudos será feita a partir de uma diferenciação entre duas categorias. A primeira diz respeito aos trabalhos que abordavam a imputação de dados inserida em SHM, no entanto, sem possuir um foco de comparação e sim, propondo novas técnicas de imputação de dados. A segunda categoria consiste de trabalhos que abordam a comparação dos diferentes métodos de imputação de dados, porém sem um foco específico na área de SHM.

1.1.1 Imputação ou recuperação de dados em SHM

Com relação aos trabalhos relacionados diretamente com a área de SHM, um estudo de Ye et al. (2017) apresentou uma abordagem de reconstrução de dados para o monitoramento de saúde de pontes com base na análise de multi-resolução *wavelet* e na máquina de vetores de suporte (SVM). Como limitação desse trabalho, é possível citar o tamanho da amostra utilizada para testes que ficou limitada em um intervalo pequeno de 5 dias e outro intervalo de apenas um dia. De qualquer maneira, o autor demonstrou que a abordagem pode ser um ferramente efetiva para a imputação de dados faltantes.

Outro estudo dentro da área de SHM foi o de [Ji, Sun e Shen \(2014\)](#) que estudou a perda de dados que ocorre durante a transmissão de dados entre nós sensores e a estação base. Neste artigo, um método para recuperar dados perdidos em redes sem fio baseado em sensoriamento compressivo (*compressive sensing* - CS) é proposto. Em comparação com os métodos existentes, é um método de recuperação de dados simples e estável e que pode obter uma baixa margem de erro dos dados recuperados para a perda de dados unidimensional em SHM. No entanto, como se trata de uma técnica de processamento de sinais e não especificamente de imputação de dados, o método proposto pelo artigo não se aplica à comparação de técnicas proposta neste estudo.

Além disso, outro estudo que também abordou a perdas de dados em SHM para redes sem fio foi feito por [Yu et al. \(2015\)](#) que, propôs um algoritmo novo e melhorado, baseado em demodulador aleatório, para superar a dificuldade de dependência de microcontroladores nos algoritmos tradicionais de perda de dados. A limitação desse estudo para a análise realizada neste trabalho é a mesma do artigo citado acima, onde o algoritmo desenvolvido não se aplica ao propósito de comparação de técnicas de imputação de dados, por ser uma técnica que se encontra mais direcionada para o processamento de sinais.

Um estudo mais antigo, apresentado por [Peng e Zongbao \(2006\)](#) abordou um método de redes neurais de função de base radical (RBF) para restaurar a perda de dados de desvio de uma determinada ponte. Outro estudo realizado por [Zhao, Jia e Zheng \(2009\)](#) propôs um método de restauração de dados usando redes neurais de propagação reversa (*backward propagation* - BP) para resolver o problema de perda de dados no monitoramento de desempenho de pontes de aço de grande extensão. Embora as redes neurais RBF ou BP possam prever dados perdidos, é difícil escolher o modelo de rede neural apropriado. Mesmo para a mesma área de monitoramento, a abordagem para estabelecer um modelo de rede neural não é a mesma de diferentes ângulos.

1.1.2 Comparação de métodos de imputação de dados

Com relação aos trabalhos relacionados diretamente com a comparação entre métodos de imputação de dados, um estudo relacionado ao campo da medicina, realizado por [Waljee et al. \(2013\)](#) abordou essa comparação para dados laboratoriais ausentes. O trabalho tinha como objetivo comparar a precisão de quatro métodos de imputação para dados faltantes de laboratório de forma completamente aleatória, além de comparar o efeito dos valores imputados na precisão de dois modelos preditivos clínicos. Os métodos utilizados foram *missForest*, imputação por média, imputação por vizinho mais próximo e MICE (*multivariate imputation by chained equations*). Esse estudo é bastante similar ao que será feito nesse trabalho, no que se refere à verificar o efeito dos valores imputados na precisão dos modelos de predição, que nesse caso, será detecção de danos em SHM. A desvantagem desse trabalho para o propósito deste trabalho seria apenas o fato de que o

banco de dados utilizado não se trata de uma série temporal, como é o caso da análise que será feita em SHM.

Outro artigo relacionado, feito por [Moritz et al. \(2015\)](#), teve como foco oferecer uma visão geral dos métodos de imputação de séries temporais univariadas em geral, além de fornecer uma visão detalhada das respectivas implementações nos pacotes disponíveis na linguagem R. Um ponto interessante neste trabalho consiste no fato dos autores terem trabalho com técnicas de imputação que se aplicavam as séries temporais, visto que a maioria dos algoritmos de imputação depende de correlações entre atributos, enquanto a imputação de séries temporais univariadas precisa empregar dependências no tempo ([MORITZ et al., 2015](#)).

Além disso, um estudo de comparação foi feito por [J \(2015\)](#), onde o autor comparou 6 diferentes métodos de imputação, incluindo imputação por média e KNN (K-vizinhos mais próximos), técnicas que farão parte da análise deste trabalho. A comparação foi realizada em quatro conjuntos de dados reais de vários tamanhos (de 4 a 65 variáveis), sob uma suposição completamente aleatória (MCAR), e baseada em quatro critérios de avaliação: Erro quadrático médio (RMSE), erro de classificação não supervisionado (UCE), erro de classificação supervisionada (SCE) e tempo de execução. Uma limitação seria que o estudo realizado ficou restrito a matrizes de dados de valores numéricos, e não foi considerado o caso de dados longitudinais ou nominais.

Por último, um trabalho desenvolvido por [Yozgatligil et al. \(2013\)](#) visou comparar várias técnicas de imputação para completar os valores ausentes de séries temporais meteorológicas espaço-temporais. Para este fim, seis métodos de imputação foram avaliados com relação a vários critérios, incluindo acurácia, robustez, precisão e eficiência para dados perdidos artificialmente criados em séries de precipitação total média e temperatura média obtidas do Serviço Meteorológico do Estado Turco. Um aspecto interessante deste estudo é a inserção artificial de dados perdidos, algo que também será aplicado para os propósitos deste trabalho.

1.2 Motivação

O Monitoramento de Saúde Estrutural (SHM) tem atraído inúmeros esforços de pesquisa ao redor do mundo porque visa monitorar condições estruturais e desempenho para prevenir falhas catastrófica, além de fornecer dados quantitativos para engenheiros e proprietários de infraestrutura a fim de que os mesmos possam projetar uma estratégia de gerenciamento segura ([LI; HAO, 2016](#)).

No entanto, em uma rede densa de sensores com sensores de baixo custo, é bastante provável que alguns sensores venham a falhar, resultando em dados defeituosos para inferência e decisão ([KULLAA, 2011](#)). Além disso, séries temporais coletadas, que é o caso

de SHM, são frequentemente incompletas devido à natureza do monitoramento estático de longo prazo (WEI; TANG, 2003). Por exemplo, a manutenção periódica do sistema pode gerar interrupções de medições e, conseqüentemente, criar grandes lacunas na série temporal. Valores faltantes também podem ser devidos a falhas do instrumento, fenômenos naturais extremos, interrupções de energia ou simplesmente devido à remoção de medições errôneas (POSENATO et al., 2010).

Em particular, dentro da área de SHM, estruturas complexas e ambientes hostis frequentemente levam à perda contínua de dados ou à perda aleatória de dados durante a transmissão de dados. Esses dados imperfeitos afetarão a precisão da identificação de danos estruturais e, assim, levarão a decisões erradas (JI; SUN; SHEN, 2014).

Um estudo realizado por Nagayama et al. (2007) encontrou resultados experimentais que mostram que a perda de 0,5% dos dados afeta a função de coerência de uma maneira similar à adição de ruído de medição de 5 a 10%. Dessa maneira, é possível verificar que a perda de dados é um problema crítico no monitoramento de integridade estrutural (JI; SUN; SHEN, 2014).

Portanto, a preparação de dados é uma etapa extremamente crítica a fim de solucionar o problema dos valores ausentes. Encontrou-se que os métodos de imputação de dados possuem um desempenho melhor que a exclusão por lista ou a exclusão em pares (POSENATO et al., 2010).

Nesse contexto se torna importante uma comparação entre diferentes métodos de imputação no contexto específico de SHM a fim de verificar se existe um desempenho muito superior comparando-se à exclusão e qual técnica se adapta melhor ao domínio específico de monitoramento de integridade estrutural.

1.3 Justificativa

Considerando os estudos apresentados nos trabalhos relacionados e levando em conta o que já se encontra dentro da literatura, este trabalho surge dentro desse contexto com o objetivo de comparar diferentes técnicas de imputação de dados no domínio específico de SHM. Após revisão dos estudos similares, é possível verificar que existem diversos trabalhos que realizam essa comparação de diversos métodos de recuperação de dados faltantes no entanto não possuem um foco específico na área de monitoramento da integridade das estruturas. Assim como também existem diversos trabalhos dedicados ao desenvolvimento de novas técnicas de imputação de dados dentro do contexto de SHM, no entanto, são trabalhos focados na construção de novos métodos e não na comparação entre os diversos métodos já existentes.

A justificativa para a existência desse trabalho seria então suprir essa lacuna na

literatura, oferecendo uma visão geral sobre algumas técnicas de imputação de dados com relação à sua aplicação específica em SHM. Foram utilizados os métodos de média, interpolação e K-Nearest Neighbor (KNN) para realizar a imputação dos dados, por serem métodos com uma baixa complexidade de implementação além de estarem entre os mais presentes na literatura.

Para a etapa de detecção de danos a escolha dos algoritmos utilizados se deu por serem métodos de clusterização simples, bastante conhecidos e eficientes na literatura de aprendizado de máquina. Essas técnicas variam de clusterização em centroides e por densidade, *soft* e *hard* e paramétricas e não paramétricas. Com toda essa variedade se espera que sejam encontradas mais combinações que possam ser usadas em SHM, ao avaliar o método de imputação utilizado em conjunto com a técnicas de detecção de danos.

1.4 Objetivos

1.4.1 Objetivo Geral

O objetivo desse trabalho é comparar diferentes técnicas de imputação de dados no domínio específico de SHM. Os resultados permitirão definir quais os melhores métodos específicos para essa área, levando em conta não só a taxa de dados faltantes como o poder computacional exigido para cada técnica, juntamente com o tempo necessário para executar cada uma.

1.4.2 Objetivos Específicos

Considerando o desenvolvimento do trabalho e o objetivo geral apresentado, destacam-se os seguintes objetivos específicos:

- Revisão e estudo da literatura de SHM, tanto na área de imputação de dados quanto na área de detecção de danos;
- Comparar as técnicas de imputação de dados (média, interpolação, KNN) no domínio específico de SHM, através de critérios como erro quadrático médio (*mean squared error* - MSE) e a raiz do erro quadrático médio (*root mean squared error* - RMSE)
- Avaliar as técnicas selecionadas para imputação e sua consequência na detecção de dano, através de critérios como precisão, sensibilidade, acurácia e especificidade.
- Verificar a sensibilidade do sinal conforme a porcentagem de dados faltantes aumenta, a fim de analisar em qual porcentagem o sinal começa a perder suas características.
- Implementação em *Python* das técnicas de extração de *features* a partir do sinal, sendo que as mesmas só estavam disponíveis para *MATLAB*.

1.5 Metodologia

O presente trabalho teve como ponto de partida um estudo e revisão da literatura atual de SHM, tendo como foco principal as técnicas de imputação de dados utilizadas na área assim como as técnicas de detecção de danos. Além disso foi pesquisado na literatura de imputação de dados novas técnicas utilizadas na recuperação de dados faltantes, bem como na literatura de aprendizado de máquina novas técnicas que pudessem ser utilizadas para detecção de danos em SHM. A partir desse estudo foi possível entender o atual estado da arte e escolher as técnicas mais relevantes para esse trabalho, tanto no que se refere à imputação de dados, quanto ao que se refere à detecção de danos.

Para realizar os testes foram utilizados os dados extraídos da ponte Z24 na Suíça. Foram coletados os dados do sensor número 5, extraídos as 12h da tarde, resultando em um total 234 amostras. Para cada amostra, realizou-se um processo de extração de dados, a fim de simular o que aconteceria no caso de falhas no sensor, ocasionando então dados faltantes. Foram testados diferentes métodos de imputação em conjunto com diferentes métodos de detecção de danos, além de variar a porcentagem de dados faltantes.

Com a imputação realizada, os dados foram divididos para treino e testes. O treino foi realizado com as amostras coletadas nos primeiros 158 dias, todas sem dano. Os testes foram realizados utilizando toda as 234 amostras, sendo as 197 primeiras sem dano e o restante com dano.

Foram aplicados os algoritmos de aprendizado de máquina de clusterização selecionados para os testes. Para cada teste foi calculado os centros de cada cluster com as amostras de treino e calculado a distância euclidiana de cada amostra para o centro para encontrar o indicador de dano (DI) da mesma. O DI da que ocupa a posição de 95% dos DIs de treino ordenados é escolhido como o limiar de dano. As amostras de teste que tiverem um valor de DI menor que o limiar de dano são consideradas como sem dano, enquanto as outras são consideradas com dano.

Para cada combinação de técnica de imputação de dados, porcentagem de dados faltantes e método de detecção de dano, foi calculado o número de falsos positivos e falsos negativos. Utilizando os dados das quantidade de erros foram calculados os critérios: precisão, acurácia, sensibilidade e especificidade. Além disso, após o processo de imputação de dados e antes de começar o processo de detecção de dano, calculou-se mais dois critérios que comparavam a base de dados original com a base de dados após a imputação dos dados, sendo eles o erro quadrático médio (*mean squared error* - MSE) e a raiz do erro quadrático médio (*root mean squared error* - RMSE).

1.6 Organização

O presente trabalho está organizado da seguinte forma:

- Capítulo 2: Monitoramento de Integridade Estrutural;

Esse capítulo faz uma breve explicação sobre SHM e as etapas relacionadas ao processo e suas respectivas importâncias.

- Capítulo 3: Técnicas de Imputação de Dados

Aqui são feitas explicações gerais relevantes do processo de imputação dos dados, assim como é explicado o funcionamento de cada um dos algoritmos utilizados nesse trabalho.

- Capítulo 4: Detecção de Dano

É discutido o processo de detecção de dano em SHM e explicado todas as técnicas utilizadas nesse trabalho.

- Capítulo 5: Metodologia de Testes

É explicado como foram feitos os testes, a base de dados utilizada e os parâmetros escolhidos para cada uma das etapas.

- Capítulo 6: Resultados

Apresentação dos resultados obtidos nos testes e análise comparativa entre dados obtidos.

- Capítulo 7: Considerações finais

São feitas as considerações finais sobre o trabalho e discutido os possíveis futuros trabalhos que podem surgir a partir desse.

Referências

- BALABAN, E. et al. Modeling, detection, and disambiguation of sensor faults for aerospace applications. v. 9, p. 1907 – 1917, 01 2010. Citado na página 12.
- BALAGEAS, D.; FRITZEN, C.-P.; GÜEMES, A. *Structural health monitoring*. [S.l.]: John Wiley & Sons, 2010. v. 90. Citado na página 11.
- BAO, Y. et al. Compressive sampling-based data loss recovery for wireless sensor networks used in civil structural health monitoring. *Structural Health Monitoring*, v. 12, n. 1, p. 78–95, 2013. Disponível em: <<https://doi.org/10.1177/1475921712462936>>. Citado na página 12.
- CHEN, Z. et al. A novel distribution regression approach for data loss compensation in structural health monitoring. *Structural Health Monitoring*, v. 0, n. 0, p. 1475921717745719, 2017. Disponível em: <<https://doi.org/10.1177/1475921717745719>>. Citado na página 12.
- GLIŠIĆ, B.; INAUDI, D. Fibre optic methods for structural health monitoring. p. 1–262, 11 2007. Citado na página 11.
- J, S. P. M. A comparison of six methods for missing data imputation. v. 06, 01 2015. Citado na página 14.
- JEREZ, J. M. et al. Missing data imputation using statistical and machine learning methods in a real breast cancer problem. *Artificial Intelligence in Medicine*, v. 50, n. 2, p. 105 – 115, 2010. ISSN 0933-3657. Disponível em: <<http://www.sciencedirect.com/science/article/pii/S0933365710000679>>. Citado na página 12.
- JI, S.; SUN, Y.; SHEN, J. A method of data recovery based on compressive sensing in wireless structural health monitoring. *Mathematical Problems in Engineering*, Hindawi, v. 2014, 2014. Citado 2 vezes nas páginas 13 e 15.
- KULLAA, J. Separating three sources of changes in structural health monitoring. In: *Sensors, Instrumentation and Special Topics, Volume 6*. Springer New York, 2011. p. 17–25. Disponível em: <https://doi.org/10.1007/978-1-4419-9507-0_3>. Citado na página 14.
- LI, H.-N.; YI, T.-H.; QIAO, P. Special issue on health monitoring technologies for civil infrastructure. *Journal of Aerospace Engineering*, v. 30, n. 2, p. B2017001, 2017. Citado na página 11.
- LI, J.; HAO, H. A review of recent research advances on structural health monitoring in western australia. v. 3, p. 33–49, 03 2016. Citado na página 14.
- MORITZ, S. et al. Comparison of different methods for univariate time series imputation in r. *arXiv preprint arXiv:1510.03924*, 2015. Citado na página 14.

- NAGAYAMA, T. et al. Issues in structural health monitoring employing smart sensors. *Smart Structures and Systems*, Techno-Press, v. 3, n. 3, p. 299–320, 2007. Citado na página 15.
- NOEL, A. B. et al. Structural health monitoring using wireless sensor networks: A comprehensive survey. *IEEE Communications Surveys Tutorials*, v. 19, n. 3, p. 1403–1423, thirdquarter 2017. Citado na página 11.
- PENG, H. S. C. W. Z.; ZONGBAO, F. Y. L. Research of bridge deflection restoring based on rbf neural networks [j]. *Chinese Journal of Scientific Instrument*, v. 12, p. 009, 2006. Citado na página 13.
- POSENATO, D. et al. Methodologies for model-free data interpretation of civil engineering structures. *Computers & structures*, Elsevier, v. 88, n. 7-8, p. 467–482, 2010. Citado na página 15.
- SANTOS, A. et al. Output-only structural health monitoring based on mean shift clustering for vibration-based damage detection. 07 2016. Citado na página 11.
- SPENCER, B.; NAGAYAMA, T.; BRIDGE, J. Structural health monitoring using smart sensors. 07 2008. Citado na página 12.
- WALJEE, A. K. et al. Comparison of imputation methods for missing laboratory data in medicine. *BMJ open*, British Medical Journal Publishing Group, v. 3, n. 8, p. e002847, 2013. Citado na página 13.
- WEI, W.; TANG, Y. *A generic neural network approach for filling missing data in data mining*. 2003. 862 - 867 vol.1 p. Citado na página 15.
- YE, X. et al. Structural health monitoring data reconstruction of a concrete cable-stayed bridge based on wavelet multi-resolution analysis and support vector machine. v. 20, p. 555–562, 11 2017. Citado na página 12.
- YOZGATLIGIL, C. et al. Comparison of missing value imputation methods in time series: the case of turkish meteorological data. *Theoretical and applied climatology*, Springer, v. 112, n. 1-2, p. 143–167, 2013. Citado na página 14.
- YU, Y. et al. A study on data loss compensation of wifi-based wireless sensor networks for structural health monitoring. v. 16, p. 1–1, 01 2015. Citado na página 13.
- ZHAO, X.; JIA, J.; ZHENG, Y.-m. Strain monitoring data restoring of large-span steel skybridge based on bp neural network [j]. *Journal of Architecture and Civil Engineering*, v. 1, p. 019, 2009. Citado na página 13.